

# **Curso de Programação Estatística**

Andressa Cerqueira, Rafael Izbicki, Thiago Ramos

2024-10-04

# Table of contents

<b>Curso de Programação Estatística</b>	<b>5</b>
Objetivo Geral . . . . .	5
<b>1 Geração de Números Aleatórios e Aplicação em Problemas Estatísticos</b>	<b>6</b>
1.1 Objetivo da Aula . . . . .	6
1.2 Conteúdo Teórico . . . . .	6
1.3 Exemplo de Problema . . . . .	6
<b>2 R</b>	<b>7</b>
<b>3 Python</b>	<b>9</b>
3.1 Exemplo: Simulação de um Jogo de Dados com Dado “Viciado” . . . . .	10
<b>4 R</b>	<b>12</b>
<b>5 Python</b>	<b>14</b>
5.1 Pergunta: precisamos da função <code>np.random.choice/set.seed?</code> . . . . .	15
<b>6 R</b>	<b>16</b>
<b>7 Python</b>	<b>20</b>
<b>8 Geração de Números Pseudoaleatórios</b>	<b>23</b>
8.1 O que é um número pseudoaleatório? . . . . .	23
8.2 Geração de Números Pseudoaleatórios com o Gerador Linear Congruente (LCG)	23
<b>9 R</b>	<b>25</b>
<b>10 Python</b>	<b>26</b>
10.1 Por que o Gerador Linear Congruente Funciona? . . . . .	26
<b>11 R</b>	<b>29</b>
<b>12 Python</b>	<b>31</b>
<b>13 R</b>	<b>34</b>

<b>14 Python</b>	<b>36</b>
14.1 Gerando números uniformes com uma moeda . . . . .	37
<b>15 R</b>	<b>38</b>
<b>16 Python</b>	<b>40</b>
<b>17 Geração de Variáveis Aleatórias Discretas Usando a Técnica da Inversão</b>	<b>42</b>
17.1 Geração de Variáveis Aleatórias Discretas Genéricas . . . . .	42
<b>18 R</b>	<b>43</b>
<b>19 Python</b>	<b>45</b>
19.1 Inversa da CDF . . . . .	46
19.2 Geração de Variáveis Aleatórias com Distribuição Geométrica . . . . .	46
<b>20 R</b>	<b>49</b>
<b>21 Python</b>	<b>52</b>
21.1 Geração de Variáveis Aleatórias com Distribuição Poisson . . . . .	54
<b>22 R</b>	<b>56</b>
<b>23 Python</b>	<b>59</b>
23.1 Exercícios . . . . .	61
<b>24 Geração de Variáveis Aleatórias Contínuas Usando a Técnica da Inversão e Transformações</b>	<b>63</b>
24.1 Função Inversa . . . . .	63
<b>25 R</b>	<b>64</b>
<b>26 Python</b>	<b>66</b>
26.1 Método da Inversão . . . . .	68
26.2 Exemplo 1 . . . . .	68
<b>27 R</b>	<b>69</b>
<b>28 Python</b>	<b>71</b>
<b>29 R</b>	<b>73</b>
<b>30 Python</b>	<b>75</b>
30.1 Simulação de transformações de variáveis aleatórias . . . . .	76
<b>31 R</b>	<b>77</b>

<b>32 Python</b>	<b>79</b>
<b>33 R</b>	<b>81</b>
<b>34 Python</b>	<b>83</b>
34.1 Exercícios . . . . .	84
<b>35 Geração de Variáveis Aleatórias Discretas Usando o Método da Rejeição</b>	<b>86</b>
<b>36 Geração de Variáveis Aleatórias Contínuas Usando o Método da Rejeição</b>	<b>87</b>
36.1 Algoritmo . . . . .	87
<b>37 R</b>	<b>88</b>
<b>38 Python</b>	<b>90</b>
38.1 Exemplo . . . . .	92
<b>39 R</b>	<b>93</b>
<b>40 Python</b>	<b>95</b>
40.1 Resultados Teóricos . . . . .	96
40.2 Exercícios . . . . .	99
<b>References</b>	<b>100</b>

# Curso de Programação Estatística

## Objetivo Geral

Este curso visa explorar o impacto das representações numéricas nos resultados de algoritmos de análise estatística. O foco será na programação, visualização e preparação de dados, além de discutir tópicos importantes como aleatoriedade, pseudoaleatoriedade, erros de truncamento e arredondamento, entre outros. O curso inclui ainda uma introdução à inferência por simulação estocástica, utilizando métodos como Monte Carlo e integrações numéricas. O material do curso foi amplamente baseado nas discussões apresentadas em Ross (2006).

Autores: [Andressa Cerqueira](#), [Rafael Izbicki](#), [Thiago Rodrigo Ramos](#)

# 1 Geração de Números Aleatórios e Aplicação em Problemas Estatísticos

## 1.1 Objetivo da Aula

Nesta aula, vamos introduzir o conceito de números pseudoaleatórios e como eles podem ser usados para resolver problemas estatísticos por meio de simulação. Vamos abordar a importância da aleatoriedade em estatísticas e em algoritmos de Monte Carlo.

## 1.2 Conteúdo Teórico

A geração de números aleatórios é essencial em várias áreas da estatística e da ciência de dados. Esses números são utilizados em simulações estocásticas, amostragem e para resolver problemas que envolvem incerteza. Contudo, em computadores, os números “aleatórios” gerados são na verdade pseudoaleatórios, pois seguem uma sequência previsível, gerada por um algoritmo determinístico.

Os números pseudoaleatórios são amplamente usados em algoritmos de Monte Carlo, que dependem da simulação repetida de processos aleatórios para estimar soluções para problemas matemáticos e estatísticos.

## 1.3 Exemplo de Problema

Vamos resolver o problema de estimar o valor de  $\pi$  (Pi) usando um método de Monte Carlo. A ideia é simular a área de um quarto de círculo inscrito em um quadrado. Gerando pontos aleatórios dentro do quadrado, podemos calcular a proporção desses pontos que também caem dentro do círculo e usar essa proporção para estimar o valor de  $\pi$ .

**Como fazer isso?**

## 2 R

```
# Definindo o número de pontos a serem gerados
n_pontos <- 1000

# Gerando pontos aleatórios (x, y) no intervalo [0, 1]
x <- runif(n_pontos, 0, 1)
y <- runif(n_pontos, 0, 1)

# Calculando a distância de cada ponto à origem
distancia <- sqrt(x^2 + y^2)

# Contando quantos pontos estão dentro do quarto de círculo (distância <= 1)
dentro_circulo <- distancia <= 1
pi_estimado <- 4 * sum(dentro_circulo) / n_pontos

# Exibindo o valor estimado de Pi
cat("Valor estimado de :", pi_estimado, "\n")
```


Valor estimado de : 3.136

```
# Visualizando a distribuição dos pontos
library(ggplot2)

dados <- data.frame(x = x, y = y, dentro_circulo = dentro_circulo)

ggplot(dados, aes(x = x, y = y, color = dentro_circulo)) +
  geom_point(size = 1) +
  scale_color_manual(values = c("red", "blue")) +
  ggtitle(paste0("Estimativa de usando Monte Carlo\nValor estimado: ", round(pi_estimado, 5))) +
  theme_minimal() +
  coord_equal() +
  labs(x = "x", y = "y")
```

Estimativa de .. usando Monte Carlo  
Valor estimado: 3.136





## 3 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Definindo o número de pontos a serem gerados
n_pontos = 1000

# Gerando pontos aleatórios (x, y) no intervalo [0, 1]
x = np.random.uniform(0, 1, n_pontos)
y = np.random.uniform(0, 1, n_pontos)


# Calculando a distância de cada ponto à origem
distancia = np.sqrt(x**2 + y**2)

# Contando quantos pontos estão dentro do quarto de círculo (distância <= 1)
dentro_circulo = distancia <= 1
pi_estimado = 4 * np.sum(dentro_circulo) / n_pontos

# Exibindo o valor estimado de Pi
print(f"Valor estimado de : {pi_estimado}")
```

Valor estimado de : 3.108

```
# Visualizando a distribuição dos pontos
plt.figure(figsize=(6,6))
plt.scatter(x, y, c=dentro_circulo, cmap='coolwarm', s=1)
plt.title(f'Estimativa de usando Monte Carlo\nValor estimado: {pi_estimado}')
plt.xlabel('x')
plt.ylabel('y')
plt.show()
```



### 3.1 Exemplo: Simulação de um Jogo de Dados com Dado “Viciado”

Imagine que estamos jogando um jogo em que o dado é “viciado” e não segue uma distribuição uniforme, ou seja, alguns números têm uma chance maior de serem sorteados. Por exemplo, o número 6 pode ter uma probabilidade maior, e os outros números, menores.

Isso nos permite mostrar como alterar a probabilidade de ocorrência de eventos em uma

distribuição discreta.

## 4 R

```
# Definindo as faces do dado e as probabilidades
faces <- 1:6
probabilidades <- c(0.05, 0.1, 0.15, 0.2, 0.25, 0.25) # Probabilidades associadas às faces

# Verificando que a soma das probabilidades é 1
cat("Soma das probabilidades:", sum(probabilidades), "\n")
```

Soma das probabilidades: 1

```
# Simulando 10000 lançamentos de um dado viciado
n_lancamentos <- 10000
set.seed(123) # Definindo seed para reprodutibilidade
resultados <- sample(faces, size = n_lancamentos, replace = TRUE, prob = probabilidades)

# Contando as frequências de cada face
frequencias <- table(resultados) / n_lancamentos

# Exibindo os resultados da simulação
cat("Frequências de cada face após", n_lancamentos, "lançamentos:\n")
```

Frequências de cada face após 10000 lançamentos:


```
for (face in faces) {
  cat("Face", face, ":", frequencias[as.character(face)], "vezes\n")
}
```

```
Face 1 : 0.0473 vezes
Face 2 : 0.0975 vezes
Face 3 : 0.1504 vezes
Face 4 : 0.1991 vezes
Face 5 : 0.2582 vezes
Face 6 : 0.2475 vezes
```

```
# Visualizando os resultados em um gráfico de barras
library(ggplot2)

dados <- data.frame(faces = as.factor(faces), frequencias = as.numeric(frequencias))

ggplot(dados, aes(x = faces, y = frequencias)) +
  geom_bar(stat = "identity", fill = "lightcoral", color = "black") +
  ggtitle(paste0("Simulação de Lançamentos de um Dado Viciado\n", n_lancamentos, " lançamentos")) +
  xlab("Face do Dado") +
  ylab("Frequência de Ocorrência") +
  theme_minimal() +
  geom_text(aes(label = round(frequencias, 4)), vjust = -0.5) +
  theme(panel.grid.major = element_line(color = "grey80"))
```



## 5 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Definindo as faces do dado e as probabilidades
faces = [1, 2, 3, 4, 5, 6]
probabilidades = [0.05, 0.1, 0.15, 0.2, 0.25, 0.25] # Probabilidades associadas às faces do

# Verificando que a soma das probabilidades é 1
print(f"Soma das probabilidades: {sum(probabilidades)}")
```

Soma das probabilidades: 1.0

```
# Simulando 10000 lançamentos de um dado viciado
n_lancamentos = 10000
resultados = np.random.choice(faces, size=n_lancamentos, p=probabilidades)

# Contando as frequências de cada face
frequencias = [np.sum(resultados == face) / n_lancamentos for face in faces]

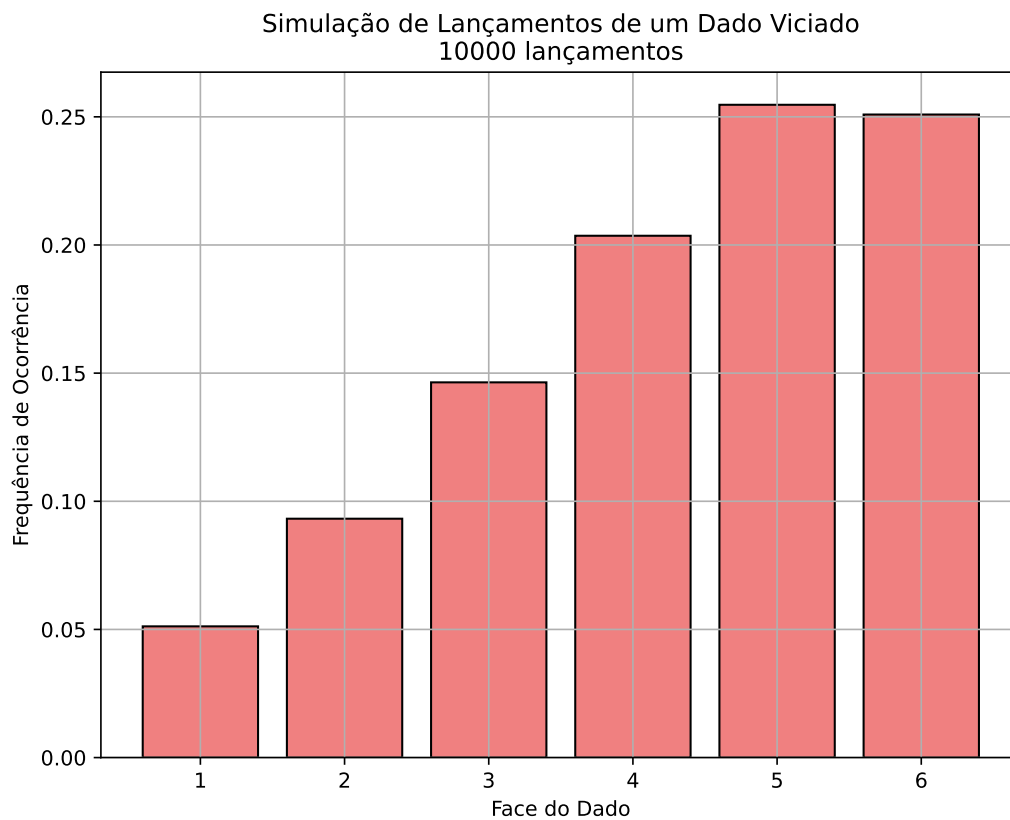
# Exibindo os resultados da simulação
print(f"Frequências de cada face após {n_lancamentos} lançamentos:")
```

Frequências de cada face após 10000 lançamentos:

```
for face, freq in zip(faces, frequencias):
    print(f"Face {face}: {freq} vezes")
```

Face 1: 0.0512 vezes  
Face 2: 0.0932 vezes  
Face 3: 0.1464 vezes  
Face 4: 0.2036 vezes  
Face 5: 0.2547 vezes  
Face 6: 0.2509 vezes

```
# Visualizando os resultados em um gráfico de barras
plt.figure(figsize=(8,6))
plt.bar(faces, frequencias, color='lightcoral', edgecolor='black')
plt.title(f'Simulação de Lançamentos de um Dado Viciado\n{n_lancamentos} lançamentos')
plt.xlabel('Face do Dado')
plt.ylabel('Frequência de Ocorrência')
plt.grid(True)
plt.show()
```



## 5.1 Pergunta: precisamos da função `np.random.choice/set.seed`?

## 6 R

```
# Definindo as faces do dado e as probabilidades associadas (não uniformes)
faces <- 1:6
probabilidades <- c(0.05, 0.1, 0.15, 0.2, 0.25, 0.25) # Probabilidades associadas às faces do dado

# Função para gerar uma amostra baseada em intervalos de probabilidades
gerar_amostra_por_intervalos <- function(probabilidades, faces) {
  u <- runif(1) # Gerando um número aleatório uniforme
  limite_inferior <- 0 # Limite inferior do intervalo

  # Percorrendo as probabilidades e verificando em qual intervalo o número cai
  for (i in seq_along(probabilidades)) {
    limite_superior <- limite_inferior + probabilidades[i] # Definindo o limite superior do intervalo
    if (limite_inferior <= u && u < limite_superior) {
      return(faces[i]) # Retorna a face correspondente ao intervalo
    }
    limite_inferior <- limite_superior # Atualiza o limite inferior para o próximo intervalo
  }
}

# Simulando lançamentos do dado viciado utilizando a verificação dos intervalos
n_lancamentos <- 10000
set.seed(123) # Definindo seed para reprodutibilidade
resultados <- replicate(n_lancamentos, gerar_amostra_por_intervalos(probabilidades, faces))

# Contando as frequências de cada face
frequencias <- sapply(faces, function(face) sum(resultados == face) / n_lancamentos)

# Exibindo os resultados da simulação
cat("Frequências de cada face após", n_lancamentos, "lançamentos:\n")
```

Frequências de cada face após 10000 lançamentos:



```
for (i in seq_along(faces)) {  
  cat("Face", faces[i], ":", frequencias[i], "vezes\n")  
}
```


```
Face 1 : 0.0521 vezes  
Face 2 : 0.0964 vezes  
Face 3 : 0.1527 vezes  
Face 4 : 0.2045 vezes  
Face 5 : 0.2508 vezes  
Face 6 : 0.2435 vezes
```

```
# Visualizando os resultados em gráficos
```

```
library(ggplot2)
```

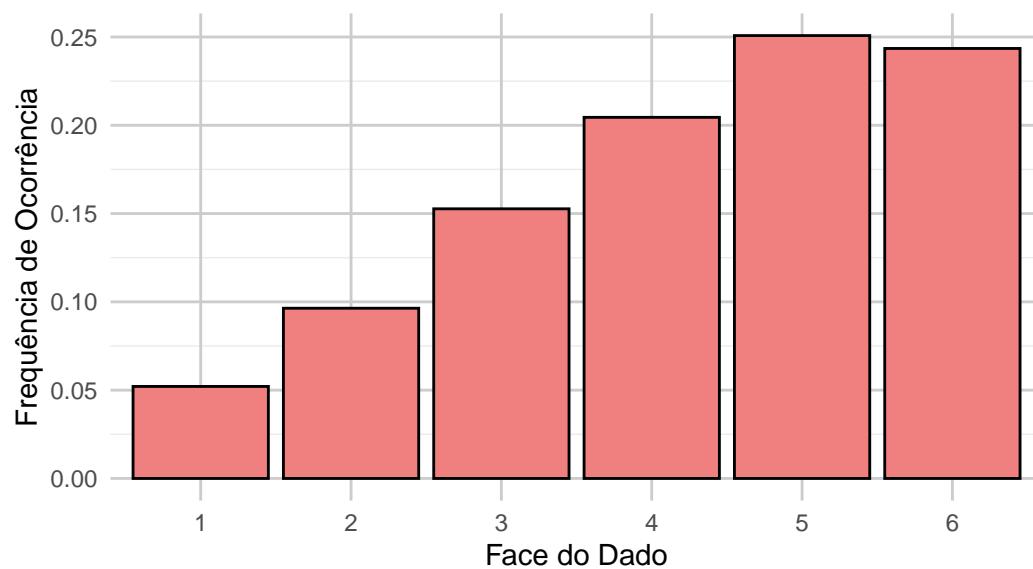
```
# Gráfico das probabilidades ajustadas
```

```
dados_probabilidades <- data.frame(faces = as.factor(faces), probabilidades = probabilidades)  
ggplot(dados_probabilidades, aes(x = faces, y = probabilidades)) +  
  geom_bar(stat = "identity", fill = "skyblue", color = "black") +  
  ggtitle("Probabilidades Ajustadas para o Dado Viciado") +  
  xlab("Face do Dado") +  
  ylab("Probabilidade") +  
  theme_minimal() +  
  theme(panel.grid.major = element_line(color = "grey80"))
```



```
# Gráfico das frequências obtidas
dados_frequencias <- data.frame(faces = as.factor(faces), frequencias = frequencias)
ggplot(dados_frequencias, aes(x = faces, y = frequencias)) +
  geom_bar(stat = "identity", fill = "lightcoral", color = "black") +
  ggtitle(paste0("Simulação de Lançamentos de um Dado Viciado\n", n_lancamentos, " lançamentos")) +
  xlab("Face do Dado") +
  ylab("Frequência de Ocorrência") +
  theme_minimal() +
  theme(panel.grid.major = element_line(color = "grey80"))
```

Simulação de Lançamentos de um Dado Viciado  
10000 lançamentos



## 7 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Definindo as faces do dado e as probabilidades associadas (não uniformes)
faces = [1, 2, 3, 4, 5, 6]
probabilidades = [0.05, 0.1, 0.15, 0.2, 0.25, 0.25] # Probabilidades associadas às faces do

# Gerando um número aleatório e verificando em qual intervalo ele cai
def gerar_amostra_por_intervalos(probabilidades, faces):
    u = np.random.uniform(0, 1) # Gerando um número aleatório uniforme
    limite_inferior = 0 # Limite inferior do intervalo

    # Percorrendo as probabilidades e verificando em qual intervalo o número cai
    for i, p in enumerate(probabilidades):
        limite_superior = limite_inferior + p # Definindo o limite superior do intervalo
        if limite_inferior <= u < limite_superior:
            return faces[i] # Retorna a face correspondente ao intervalo
        limite_inferior = limite_superior # Atualiza o limite inferior para o próximo inter

# Simulando lançamentos do dado viciado utilizando a verificação dos intervalos
n_lancamentos = 10000
resultados = [gerar_amostra_por_intervalos(probabilidades, faces) for _ in range(n_lancamentos)]

# Contando as frequências de cada face
frequencias = [np.sum(np.array(resultados) == face) / n_lancamentos for face in faces]

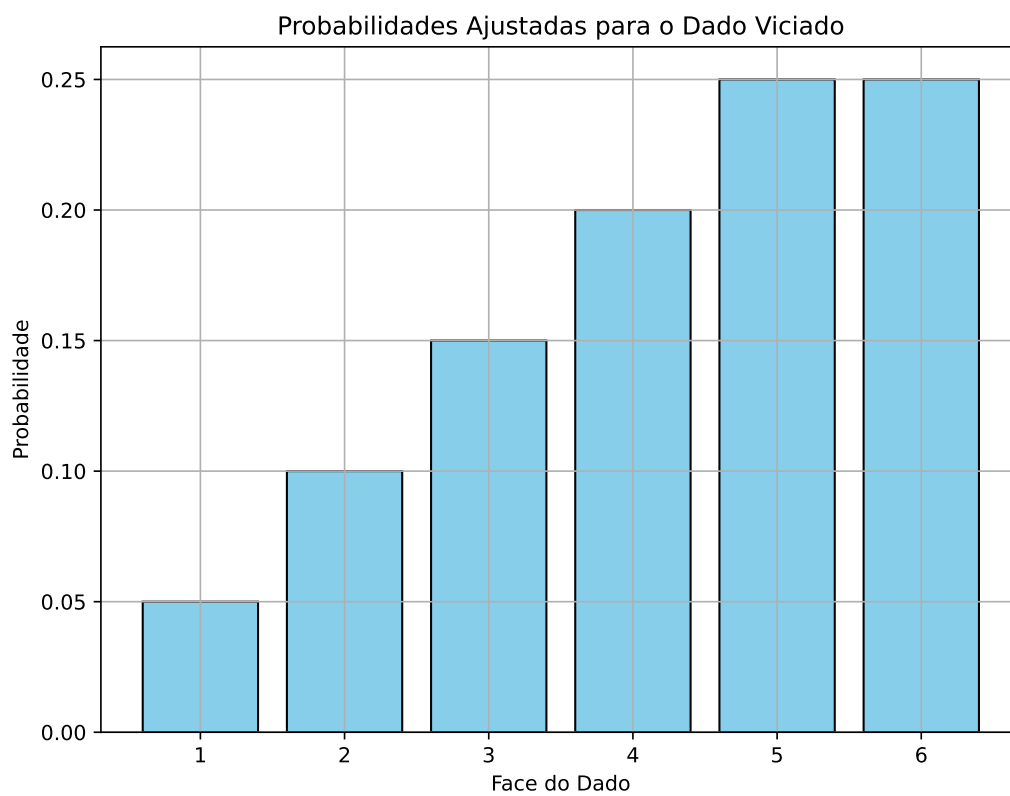
# Exibindo os resultados da simulação
print(f"Frequências de cada face após {n_lancamentos} lançamentos:")
```

Frequências de cada face após 10000 lançamentos:


```
for face, freq in zip(faces, frequencias):
    print(f"Face {face}: {freq} vezes")
```

Face 1: 0.0509 vezes  
Face 2: 0.094 vezes  
Face 3: 0.1549 vezes  
Face 4: 0.2065 vezes  
Face 5: 0.2449 vezes  
Face 6: 0.2488 vezes

```
# Gráfico das probabilidades ajustadas
plt.figure(figsize=(8,6))
plt.bar(faces, probabilidades, color='skyblue', edgecolor='black')
plt.title('Probabilidades Ajustadas para o Dado Viciado')
plt.xlabel('Face do Dado')
plt.ylabel('Probabilidade')
plt.grid(True)
plt.show()
```



```
# Gráfico das frequências obtidas
plt.figure(figsize=(8,6))
plt.bar(faces, frequencias, color='lightcoral', edgecolor='black')
plt.title(f'Simulação de Lançamentos de um Dado Viciado\n{n_lancamentos} lançamentos')
plt.xlabel('Face do Dado')
plt.ylabel('Frequência de Ocorrência')
plt.grid(True)
plt.show()
```



**Ou seja, se conseguimos simular uma distribuição uniforme, conseguimos simular uma distribuição discreta. Isso vale de forma mais geral?**

## 8 Geração de Números Pseudoaleatórios

Números aleatórios têm muitas aplicações na computação, como em simulações, amostragem estatística, criptografia e jogos de azar. No entanto, os computadores, por serem sistemas determinísticos, não podem gerar números realmente aleatórios de forma autônoma. Em vez disso, utilizam algoritmos determinísticos que geram números que parecem aleatórios, e esses números são chamados de pseudoaleatórios.

### 8.1 O que é um número pseudoaleatório?

Um número pseudoaleatório é gerado a partir de uma fórmula matemática que, a partir de uma semente (um valor inicial), gera uma sequência de números que tem as propriedades desejadas de uma sequência aleatória. Essa sequência parece aleatória, mas se a mesma semente for usada, a sequência será a mesma.

### 8.2 Geração de Números Pseudoaleatórios com o Gerador Linear Congruente (LCG)

[Link para o wikipedia](#)

O **Gerador Linear Congruente** (LCG) é um dos métodos mais antigos e simples para gerar números pseudoaleatórios. Ele segue a fórmula:

$$X_{n+1} = (a \cdot X_n + c) \mod m$$

Onde: -  $X_n$  é o número atual (ou a semente inicial), -  $a$  é o multiplicador, -  $c$  é o incremento, -  $m$  é o módulo, ou seja, o intervalo dos números gerados.

A sequência gerada pelo LCG depende diretamente dos parâmetros  $a$ ,  $c$ ,  $m$  e da semente inicial  $X_0$ . Um conjunto mal escolhido de parâmetros pode resultar em uma sequência com um período curto, o que compromete a aleatoriedade da sequência.

### 8.2.1 O que é a Função Módulo?

A **função módulo** (também conhecida como operação de resto) retorna o **resto da divisão** de um número por outro. Em termos matemáticos, para dois números inteiros  $a$  e  $b$ , a operação módulo é representada como:

$$r = a \mod b$$

Onde: -  $a$  é o dividendo, -  $b$  é o divisor, -  $r$  é o resto da divisão de  $a$  por  $b$ .

Por exemplo, se temos  $a = 17$  e  $b = 5$ , a divisão de 17 por 5 dá 3 com um resto de 2, então:

$$17 \mod 5 = 2$$

No contexto do **Gerador Linear Congruente (LCG)**, a função módulo é usada para garantir que os números gerados fiquem dentro de um intervalo específico, geralmente entre 0 e  $m - 1$ , onde  $m$  é o módulo definido no algoritmo.



## 9 R

```
# Exemplo de uso da função módulo em R

# Definindo os valores
a <- 17
b <- 3

# Calculando o módulo de a por b
resto <- a %% b

# Exibindo o resultado
cat("O resultado de", a, "%%", b, "é:", resto, "\n")
```

O resultado de 17 %% 3 é: 2

# 10 Python

```
# Exemplo de uso da função módulo em Python

# Definindo os valores
a = 17
b = 3

# Calculando o módulo de a por b
resto = a % b

# Exibindo o resultado
print(f"O resultado de {a} % {b} é: {resto}")
```

O resultado de 17 % 3 é: 2

## 10.1 Por que o Gerador Linear Congruente Funciona?

O Gerador Linear Congruente (LCG) é um dos métodos mais simples e eficientes para gerar números pseudoaleatórios. Sua eficácia se baseia em um bom equilíbrio entre a escolha dos parâmetros (multiplicador  $a$ , incremento  $c$ , módulo  $m$  e semente inicial  $X_0$ ) e as propriedades matemáticas que garantem uma sequência suficientemente “aleatória”. Para que o LCG funcione bem, os parâmetros precisam ser cuidadosamente selecionados para garantir que a sequência gerada tenha um período longo, seja bem distribuída e evite padrões repetitivos.

### 10.1.1 A Fórmula do LCG

A fórmula básica do LCG é:

$$X_{n+1} = (a \cdot X_n + c) \mod m$$

Onde: -  $X_n$  é o número gerado na  $n$ -ésima iteração, -  $a$  é o multiplicador, -  $c$  é o incremento, -  $m$  é o módulo, -  $X_0$  é a semente inicial.

O número gerado em cada iteração é o **resto da divisão** de  $(a \cdot X_n + c)$  por  $m$ . Essa operação garante que os números fiquem dentro do intervalo  $[0, m - 1]$ . A normalização posterior geralmente transforma esses números em valores no intervalo  $[0, 1)$ .

### 10.1.2 O Papel de $m$

O valor de  $m$ , conhecido como módulo, define o intervalo no qual os números gerados estarão contidos. Em muitos casos,  $m$  é escolhido como uma potência de 2 (por exemplo,  $m = 2^{32}$  ou  $m = 2^{64}$ ) porque cálculos modulares com potências de 2 são mais rápidos em hardware.

A escolha de  $m$  também influencia o **período máximo** da sequência. Se todos os parâmetros forem escolhidos corretamente, o LCG pode gerar uma sequência com o período máximo, que é  $m$ . Isso significa que a sequência não repetirá nenhum número até que  $m$  números tenham sido gerados.

### 10.1.3 O Papel de $a$ , $c$ e a Condição de Coprimos

Para garantir que o gerador tenha o período máximo (ou seja,  $m$  números diferentes antes de repetir a sequência), a escolha dos parâmetros  $a$  (multiplicador),  $c$  (incremento) e  $m$  (módulo) deve satisfazer as seguintes condições baseadas em **teorias de números**:

1. **O incremento  $c$  deve ser coprimo com  $m$ :**

- Dois números são **coprimos** se o maior divisor comum deles for 1, ou seja,  $\gcd(c, m) = 1$ . Isso garante que, ao somar  $c$ , todos os possíveis valores de  $X_n$  possam ser atingidos antes de repetir a sequência.
- Se  $c$  não for coprimo com  $m$ , a sequência gerada pode pular certos valores, resultando em um período mais curto do que o esperado.

2. **O valor de  $a - 1$  deve ser divisível por todos os fatores primos de  $m$ :**

- Se  $m$  é uma potência de 2 (por exemplo,  $m = 2^k$ ), a escolha de  $a$  deve ser tal que  $(a - 1)$  seja divisível por 2 para garantir que o período seja maximizado.

3. **Se  $m$  for divisível por 4, então  $(a - 1)$  também deve ser divisível por 4:**

- Isso é necessário para garantir que todos os resíduos modulares possíveis possam ser gerados, especialmente quando  $m$  é uma potência de 2.

#### 10.1.4 Exemplo de uma Escolha Correta de Parâmetros

Um exemplo clássico de um bom conjunto de parâmetros é:

- $m = 2^{32}$  (módulo com 32 bits),
- $a = 1664525$  (multiplicador),
- $c = 1013904223$  (incremento),
- $X_0 = 42$  (semente inicial, que pode ser qualquer valor).

Esses parâmetros foram escolhidos para garantir que o LCG tenha um longo período e uma boa distribuição dos números gerados. O módulo  $m = 2^{32}$  é uma potência de 2, o que torna as operações modulares mais rápidas, e os valores de  $a$  e  $c$  satisfazem as condições matemáticas para maximizar o período.

# 11 R

```
# Importando o pacote necessário
library(gmp)

# Parâmetros do exemplo
m <- 2^32
a <- 1664525
c <- 1013904223

# Verificando as condições
# 1. O incremento c deve ser coprimo com m
coprimo_c_m <- gcd(c, m) == 1

# 2. a - 1 deve ser divisível por todos os fatores primos de m
a_menos_1 <- a - 1

print(a_menos_1)
```

```
[1] 1664524
```

```
# Verificando se a - 1 é divisível por 2 (único fator primo de m = 2^32)
divisivel_por_2 <- (a_menos_1 %% 2 == 0)

# 3. Se m for divisível por 4, a - 1 também deve ser divisível por 4
divisivel_por_4 <- (a_menos_1 %% 4 == 0)

list(coprimo_c_m, divisivel_por_2, divisivel_por_4)
```

```
[[1]]
[1] TRUE

[[2]]
[1] TRUE
```

```
[[3]]  
[1] TRUE
```

## 12 Python

```
import math

# Parâmetros do exemplo
m = 2**32
a = 1664525
c = 1013904223

# Verificando as condições
# 1. O incremento c deve ser coprimo com m
coprimo_c_m = math.gcd(c, m) == 1

# 2. a - 1 deve ser divisível por todos os fatores primos de m
a_menos_1 = a - 1

print(a_menos_1)
```

1664524

```
# Verificando se a - 1 é divisível por 2 (único fator primo de m = 2^32)
divisivel_por_2 = (a_menos_1 % 2 == 0)

# 3. Se m for divisível por 4, a - 1 também deve ser divisível por 4
divisivel_por_4 = (a_menos_1 % 4 == 0)

coprimo_c_m, divisivel_por_2, divisivel_por_4
```

(True, True, True)

### 12.0.1 Por que o LCG Funciona Bem?

O LCG funciona porque: - **As operações modulares** garantem que os números gerados estejam dentro de um intervalo fixo e possam cobrir todo o espaço de possíveis valores de maneira

ordenada. - **A escolha adequada dos parâmetros** garante que a sequência tenha um longo período (o maior possível dado  $m$ ), evita padrões repetitivos e assegura que a sequência seja **pseudoaleatória** o suficiente para muitas aplicações, como simulações e métodos de Monte Carlo.

No entanto, o LCG pode não ser adequado para todas as aplicações, especialmente em criptografia, onde a previsibilidade é um problema. Para a maioria dos usos científicos e de simulação, ele ainda é uma escolha eficiente e simples.

### 12.0.2 Efeito dos Parâmetros no Gerador Linear Congruente (LCG)

Os parâmetros no Gerador Linear Congruente (LCG) têm um impacto significativo sobre a qualidade e as propriedades da sequência de números pseudoaleatórios gerados. Os parâmetros principais são:

#### 1. Multiplicador $a$ :

- Esse parâmetro é essencial para garantir que a sequência de números gerados tenha um bom período (o número de valores distintos antes de a sequência começar a se repetir). Se o valor de  $a$  não for bem escolhido, o período da sequência pode ser curto e a qualidade dos números gerados diminui.
- Bons valores de  $a$  são cruciais para evitar padrões repetitivos ou ciclos curtos.

#### 2. Incremento $c$ :

- O incremento  $c$  adiciona um valor fixo à sequência e é um dos fatores que pode garantir que todos os valores no intervalo  $[0, m)$  sejam atingidos em algum momento, desde que os outros parâmetros também sejam bem escolhidos.
- Quando  $c = 0$ , o gerador é chamado de **multiplicativo**. Nessa forma, o LCG pode ter um comportamento menos uniforme.

#### 3. Módulo $m$ :

- O módulo define o intervalo dos números gerados. Comumente,  $m$  é escolhido como uma potência de 2 (por exemplo,  $m = 2^{32}$ ) para facilitar os cálculos modulares em hardware e software.
- O valor de  $m$  também determina o período máximo da sequência de números. Com um módulo de  $m$ , o período máximo teórico que o LCG pode ter é  $m$ , mas isso depende da escolha correta dos parâmetros  $a$  e  $c$ .

#### 4. Semente $X_0$ :

- A semente é o valor inicial de  $X_0$  usado pelo LCG para iniciar a sequência. Mudar a semente resultará em uma sequência diferente, mas com o mesmo período e comportamento determinado pelos outros parâmetros.



- A semente garante que o algoritmo possa ser **reproduzido**. Se dois programas utilizarem a mesma semente com os mesmos parâmetros, ambos produzirão a mesma sequência de números.

### 12.0.3 Impacto dos Parâmetros:

#### 1. Período da Sequência:

- O período é a quantidade de números gerados antes que a sequência comece a se repetir. Para obter o período máximo, os parâmetros  $a$ ,  $c$ ,  $m$  e a semente  $X_0$  precisam ser cuidadosamente escolhidos.
- Se os parâmetros não forem bons, o gerador pode produzir uma sequência com um ciclo muito curto ou, pior, um conjunto pequeno de valores.

#### 2. Distribuição dos Números:

- Embora o LCG gere números no intervalo  $[0, 1)$ , o quão bem distribuídos esses números estão nesse intervalo depende dos parâmetros.
- Parâmetros mal escolhidos podem causar uma distribuição não uniforme, onde certos intervalos terão mais números gerados que outros, levando a um comportamento indesejável.

#### 3. Padrões Repetitivos:

- Se os parâmetros forem mal escolhidos, podem surgir padrões repetitivos que comprometem a aleatoriedade dos números. Esses padrões tornam o LCG inadequado para algumas aplicações, como criptografia ou simulações que exigem alta qualidade de aleatoriedade.

Por essas razões, a escolha dos parâmetros  $a$ ,  $c$ ,  $m$  e da semente  $X_0$  é crítica para garantir que o LCG produza números pseudoaleatórios de alta qualidade e com um período longo.

## 13 R

```
# Carregando o pacote ggplot2
library(ggplot2)

# Classe para o Gerador Congruente Linear
LinearCongruentialGenerator <- setRefClass(
  "LinearCongruentialGenerator",
  fields = list(a = "numeric", c = "numeric", m = "numeric", semente = "numeric"),
  methods = list(
    initialize = function(semente, a = 1103515245, c = 12345, m = 2^32) {
      .self$a <- a
      .self$c <- c
      .self$m <- m
      .self$semente <- semente
    },
    gerar = function() {
      # Atualizando a semente
      .self$semente <- (.self$a * .self$semente + .self$c) %% .self$m
      return(.self$semente / .self$m) # Normalizando para [0, 1)
    }
  )
)


# Inicializando o gerador com uma semente
lcg <- LinearCongruentialGenerator$new(semente = 5)

# Gerando 1000 números pseudoaleatórios
numeros_gerados <- sapply(1:100000, function(x) lcg$gerar())

# Convertendo para um data.frame
dados <- data.frame(numeros_gerados = numeros_gerados)

# Plotando o histograma dos números gerados
ggplot(dados, aes(x = numeros_gerados)) +
  geom_histogram(bins = 20, fill = 'skyblue', color = 'black') +
```

```
ggtitle('Histograma dos Números Pseudoaleatórios Gerados pelo LCG') +  
xlab('Valor') +  
ylab('Frequência') +  
theme_minimal() +  
theme(panel.grid.major = element_line(color = "grey"))
```



## 14 Python

```
import matplotlib.pyplot as plt


class LinearCongruentialGenerator:
    def __init__(self, semente, a=1103515245, c=12345, m=2**32):
        self.a = a
        self.c = c
        self.m = m
        self.semente = semente

    def gerar(self):
        # Atualizando a semente
        self.semente = (self.a * self.semente + self.c) % self.m
        return self.semente / self.m # Normalizando para [0, 1)

# Inicializando o gerador com uma semente
lcg = LinearCongruentialGenerator(semente=5)

# Gerando 1000 números pseudoaleatórios
numeros_gerados = [lcg.gerar() for _ in range(100000)]

# Plotando o histograma dos números gerados
plt.figure(figsize=(10, 6))
plt.hist(numeros_gerados, bins=20, color='skyblue', edgecolor='black')
plt.title('Histograma dos Números Pseudoaleatórios Gerados pelo LCG')
plt.xlabel('Valor')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



## 14.1 Gerando números uniformes com uma moeda

## 15 R

```
# Carregando pacotes necessários
library(ggplot2)

# Função para simular o lançamento de uma moeda justa
lancar_moeda <- function() {
  # Lançar moeda justa: 0 para coroa (K) e 1 para cara (C)
  sample(c(0, 1), 1)
}


# Função para gerar um número uniformemente distribuído usando uma moeda
gerar_numero_uniforme <- function(n_bits = 32) {
  numero <- 0
  for (i in 1:n_bits) {
    bit <- lancar_moeda()
    # Atualizando o número, multiplicando pela base 2
    numero <- numero + bit * (2-(i))
  }
  return(numero)
}

# Gerando 10000 números uniformemente distribuídos
numeros_uniformes <- sapply(1:10000, function(x) gerar_numero_uniforme())

# Convertendo para um data.frame
dados <- data.frame(numeros_uniformes = numeros_uniformes)

# Plotando o histograma dos números gerados
ggplot(dados, aes(x = numeros_uniformes)) +
  geom_histogram(bins = 20, fill = 'skyblue', color = 'black') +
  ggtitle('Histograma de Números Uniformes Gerados Usando uma Moeda Justa') +
  xlab('Valor') +
  ylab('Frequência') +
  theme_minimal() +
  theme(panel.grid.major = element_line(color = "grey"))
```

Histograma de Números Uniformes Gerados Usando uma Mo



## 16 Python

```
import random
import matplotlib.pyplot as plt


# Função para simular o lançamento de uma moeda justa
def lancar_moeda():
    # Lançar moeda justa: 0 para coroa (K) e 1 para cara (C)
    return random.choice([0, 1])

# Função para gerar um número uniformemente distribuído usando uma moeda
def gerar_numero_uniforme(n_bits=32):
    numero = 0
    for i in range(n_bits):
        bit = lancar_moeda()
        # Atualizando o número, multiplicando pela base 2
        numero += bit * (2 ** -(i + 1)) # Cada bit tem um peso de 2-(posição)
    return numero

# Gerando 1000 números uniformemente distribuídos
numeros_uniformes = [gerar_numero_uniforme() for _ in range(10000)]

# Plotando o histograma dos números gerados
plt.figure(figsize=(10, 6))
plt.hist(numeros_uniformes, bins=20, color='skyblue', edgecolor='black')
plt.title('Histograma de Números Uniformes Gerados Usando uma Moeda Justa')
plt.xlabel('Valor')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```





# 17 Geração de Variáveis Aleatórias Discretas Usando a Técnica da Inversão

A **técnica da inversão** é uma maneira poderosa de gerar variáveis aleatórias (v.a.) a partir de uma distribuição arbitrária, usando números aleatórios uniformes no intervalo  $[0, 1)$ . A ideia básica é usar a **função de distribuição acumulada (CDF)** para mapear um número uniforme gerado entre 0 e 1 para o valor correspondente da v.a. discreta.

Passos Gerais para Gerar Variáveis Aleatórias Discretas com a Técnica da Inversão:

1. **Calcular a CDF** da variável aleatória que se deseja gerar.
2. **Gerar um número aleatório uniforme**  $u \in [0, 1)$ .
3. Encontrar o valor da variável aleatória cuja CDF seja maior ou igual a  $u$ .
4. Retornar esse valor como a variável aleatória gerada.

## 17.1 Geração de Variáveis Aleatórias Discretas Genéricas

Dado um conjunto de probabilidades  $p(x_i)$ , onde  $x_i$  são os valores possíveis da variável aleatória discreta, e  $p(x_i)$  são suas respectivas probabilidades, a CDF  $F(x)$  é calculada como:

$$F(x_i) = \sum_{j=1}^i p(x_j)$$

O algoritmo para gerar uma variável aleatória discreta genérica é:

1. Gerar um número aleatório  $u \in [0, 1)$ .
2. Encontrar o menor valor  $x_i$  tal que  $F(x_i) \geq u$ .
3. Retornar  $x_i$ .

## 18 R

```
# Exemplo de valores e probabilidades de uma variável aleatória discreta
valores <- c(0, 1, 2, 3, 4, 5, 6)
probabilidades <- c(0, 0.1, 0.2, 0.3, 0.25, 0.15, 0)

# Calculando a CDF
cdf <- cumsum(probabilidades)

# Gerando um número aleatório uniforme
u <- runif(1)

# Encontrando o valor correspondente na CDF
valor_gerado <- NA
for (i in seq_along(valores)) {
  if (u < cdf[i]) {
    valor_gerado <- valores[i]
    break
  }
}

# Ajustando o gráfico para corrigir a visualização da CDF e garantir que os valores estejam corretos
library(ggplot2)


# Criando um dataframe para os valores e CDF
df <- data.frame(valores = valores, cdf = cdf)

# Gráfico da CDF com número aleatório e valor gerado
ggplot(df, aes(x = valores, y = cdf)) +
  geom_step(direction = "hv", color = "blue", size = 1.5) +
  geom_hline(yintercept = u, color = "red", linetype = "dashed") +
  geom_vline(xintercept = valor_gerado, color = "green", linetype = "dashed") +
  labs(title = "Técnica da Inversão para Geração de Variável Aleatória Discreta",
       x = "Valores da Variável Aleatória",
       y = "CDF") +
  annotate("text", x = max(valores), y = u, label = sprintf("u = %.2f", u), hjust = -0.1, vjust = 1)
```

```

annotate("text", x = valor_gerado, y = max(cdf), label = paste("Valor gerado =", valor_gerado),
theme_minimal() +
theme(panel.grid = element_blank())

```



# 19 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Exemplo de valores e probabilidades de uma variável aleatória discreta
valores = [0, 1, 2, 3, 4, 5, 6]
probabilidades = [0, 0.1, 0.2, 0.3, 0.25, 0.15, 0]


# Calculando a CDF
cdf = np.cumsum(probabilidades)

# Gerando um número aleatório uniforme
u = np.random.uniform(0, 1)

# Encontre o valor correspondente na CDF
valor_gerado = None
for i, valor in enumerate(valores):
    if u < cdf[i]:
        valor_gerado = valor
        break

# Ajustando o gráfico para corrigir a visualização da CDF e garantir que os valores estejam corretos
plt.figure(figsize=(10, 6))

# Ajustando o eixo x para que a CDF comece e termine corretamente
plt.step(valores, cdf, label='CDF', color='blue', linewidth=2, where='post')
plt.axhline(y=u, color='red', linestyle='--', label=f'Número aleatório u = {u:.2f}')
plt.axvline(x=valor_gerado, color='green', linestyle='--', label=f'Valor gerado = {valor_gerado}')
plt.title('Técnica da Inversão para Geração de Variável Aleatória Discreta')
plt.xlabel('Valores da Variável Aleatória')
plt.ylabel('CDF')
plt.legend()
plt.grid(True)
plt.show()
```



## 19.1 Inversa da CDF

A **inversa da CDF** (função de distribuição acumulada), também conhecida como a **função quantil** ou **função percentil**, é uma função utilizada para gerar variáveis aleatórias a partir de uma distribuição específica.

**Definição:** Seja  $F(x)$  a função de distribuição acumulada (CDF) de uma variável aleatória  $X$ . A inversa da CDF, denotada por  $F^{-1}(p)$ , é definida como:

$$F^{-1}(p) = \inf\{x \in \mathbb{R} : F(x) \geq p\}, \quad \text{para } p \in [0, 1]$$

Em palavras: - A inversa da CDF  $F^{-1}(p)$  mapeia um número  $p$ , que representa uma probabilidade acumulada, de volta ao valor  $x$  correspondente da variável aleatória  $X$ , tal que a probabilidade acumulada até  $x$  é igual a  $p$ . - Isso significa que, se  $p = F(x)$ , então  $F^{-1}(p) = x$ .

## 19.2 Geração de Variáveis Aleatórias com Distribuição Geométrica

A distribuição geométrica modela o número de tentativas até o primeiro sucesso em uma sequência de experimentos de Bernoulli. Se a probabilidade de sucesso em cada tentativa é  $p$ ,

a PMF é dada por:

### 19.2.1 Derivação da Inversa da CDF para a Distribuição Geométrica

A fórmula da **inversa da CDF** para a distribuição geométrica foi obtida a partir da definição da função de distribuição acumulada (CDF) da distribuição geométrica e da aplicação da técnica da inversão.

#### 19.2.1.1 CDF da Distribuição Geométrica

A função de distribuição acumulada (CDF) da distribuição geométrica com parâmetro  $p$  (a probabilidade de sucesso) para o número de falhas  $k - 1$  antes do primeiro sucesso é dada por:

$$F(k) = 1 - (1 - p)^k$$

Essa equação expressa a probabilidade acumulada de obter o primeiro sucesso em até  $k$  tentativas.

#### 19.2.1.2 Inversa da CDF

Queremos encontrar a **inversa da CDF**, ou seja, a fórmula que, dado um valor  $u$  entre 0 e 1, nos permita calcular o valor  $k$  tal que  $F(k) = u$ .

Sabemos que:

$$u = F(k) = 1 - (1 - p)^k$$

Nosso objetivo é resolver essa equação para  $k$ . Vamos fazer isso passo a passo.

#### 19.2.1.3 Isolando o termo com $k$

Começamos isolando o termo  $(1 - p)^k$ :

$$u = 1 - (1 - p)^k$$

Subtraindo 1 de ambos os lados:

$$u - 1 = -(1 - p)^k$$

Multiplicando ambos os lados por  $-1$ :

$$1 - u = (1 - p)^k$$

#### 19.2.1.4 Aplicando o Logaritmo

Agora aplicamos o logaritmo natural ( $\log$  base  $e$ ) em ambos os lados para resolver  $k$ :

$$\log(1 - u) = \log((1 - p)^k)$$

Usando a propriedade dos logaritmos que permite trazer o expoente  $k$  para frente:

$$\log(1 - u) = k \cdot \log(1 - p)$$

#### 19.2.1.5 Isolando $k$

Agora, isolamos  $k$ :

$$k = \frac{\log(1 - u)}{\log(1 - p)}$$

Como  $k$  precisa ser um número inteiro (já que a distribuição geométrica conta o número de tentativas), usamos a função de arredondamento “para cima” ( $\lceil \cdot \rceil$ ), conhecida como a **função teto**:

$$k = \lceil \frac{\log(1 - u)}{\log(1 - p)} \rceil$$

### 19.2.2 Conclusão

Portanto, a fórmula da inversa da CDF da distribuição geométrica é:

$$k = \lceil \frac{\log(1 - u)}{\log(1 - p)} \rceil$$

Esta fórmula nos permite gerar variáveis aleatórias com distribuição geométrica a partir de um número aleatório uniforme  $u \in [0, 1)$ .



## 20 R

```
# Função para gerar a inversa da CDF para a distribuição geométrica
inversa_cdf_geometrica <- function(p, u) {
  # Usando a fórmula inversa da CDF geométrica:  $F^{-1}(u) = \text{ceil}(\log(1 - u) / \log(1 - p))$ 
  k <- ceiling(log(1 - u) / log(1 - p))
  return(as.integer(k))
}

# Parâmetro p da distribuição geométrica
p <- 0.5


# Gerando 1000 números uniformemente distribuídos
uniformes <- runif(1000)

# Gerando a variável aleatória geométrica correspondente para cada número uniforme
geometricas <- sapply(uniformes, inversa_cdf_geometrica, p = p)

# Plotando um histograma das variáveis geométricas geradas
library(ggplot2)

df <- data.frame(geometricas = geometricas)
ggplot(df, aes(x = geometricas)) +
  geom_histogram(bins = max(geometricas) + 1, color = "black", fill = "skyblue", boundary = "black") +
  labs(title = "Histograma de Variáveis Aleatórias Geométricas Usando a Inversa da CDF",
       x = "Valor da Variável Aleatória Geométrica",
       y = "Frequência") +
  theme_minimal() +
  theme(panel.grid.major = element_blank())
```


## Histograma de Variáveis Aleatórias Geométricas Usando a Inv



```
# Função para calcular a CDF da distribuição geométrica
cdf_geometrica <- function(k, p) {
  return(1 - (1 - p)^k)
}

# Gerando valores de k para plotar a CDF
k_values <- 1:20
cdf_values <- sapply(k_values, cdf_geometrica, p = p)

# Plotando a CDF da distribuição geométrica
df_cdf <- data.frame(k_values = k_values, cdf_values = cdf_values)
ggplot(df_cdf, aes(x = k_values, y = cdf_values)) +
  geom_step(direction = "hv", color = "blue", size = 1.5) +
  labs(title = "CDF da Distribuição Geométrica (p = 0.5)",
       x = "k (Número de tentativas até o primeiro sucesso)",
       y = "F(k)") +
  theme_minimal() +
  theme(panel.grid.major = element_blank())
```



## 21 Python

```
import numpy as np
import matplotlib.pyplot as plt


# Função para gerar a inversa da CDF para a distribuição geométrica
def inversa_cdf_geometrica(p, u):
    # Usando a fórmula inversa da CDF geométrica:  $F^{-1}(u) = \text{ceil}(\log(1 - u) / \log(1 - p))$ 
    k = np.ceil(np.log(1 - u) / np.log(1 - p))
    return int(k)

# Parâmetro p da distribuição geométrica
p = 0.5

# Gerando 100 números uniformemente distribuídos
uniformes = np.random.uniform(0, 1, 1000)

# Gerando a variável aleatória geométrica correspondente para cada número uniforme
geometricas = [inversa_cdf_geometrica(p, u) for u in uniformes]


# Plotando um histograma das variáveis geométricas geradas
plt.figure(figsize=(10, 6))
plt.hist(geometricas, bins=range(1, max(geometricas) + 1), color='skyblue', edgecolor='black')
plt.title('Histograma de Variáveis Aleatórias Geométricas Usando a Inversa da CDF')
plt.xlabel('Valor da Variável Aleatória Geométrica')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



```
# Calculando a CDF para a distribuição geométrica
def cdf_geometrica(k, p):
    return 1 - (1 - p)**k

# Gerando valores de k para plotar a CDF
k_values = np.arange(1, 21)
cdf_values = [cdf_geometrica(k, p) for k in k_values]

# Plotando a CDF da distribuição geométrica
plt.figure(figsize=(10, 6))
plt.step(k_values, cdf_values, where='post', color='blue', label='CDF Geométrica', linewidth=2)
plt.title('CDF da Distribuição Geométrica (p = 0.3)')
plt.xlabel('k (Número de tentativas até o primeiro sucesso)')
plt.ylabel('F(k)')
plt.grid(True)
plt.legend()
plt.show()
```



## 21.1 Geração de Variáveis Aleatórias com Distribuição Poisson

A distribuição de Poisson é usada para modelar o número de eventos que ocorrem em um intervalo de tempo ou espaço fixo, onde os eventos ocorrem com uma taxa constante  $\lambda$  e de forma independente.

A função de probabilidade de massa (PMF) da distribuição de Poisson é dada por:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

### 21.1.1 Derivação da Inversa da CDF para a Distribuição Poisson Usando a Fórmula Recursiva

A **distribuição de Poisson** tem uma fórmula recursiva que pode ser usada para calcular as probabilidades de forma mais eficiente. Em vez de recalcular a probabilidade  $P(X = k)$  a cada vez, podemos usar a seguinte relação recursiva:

$$P(X = k + 1) = \frac{\lambda}{k + 1} \cdot P(X = k)$$

Onde  $P(X = 0) = e^{-\lambda}$ .

Essa relação recursiva permite gerar variáveis aleatórias de Poisson sem precisar calcular fatoriais repetidamente, o que é mais eficiente para grandes valores de  $\lambda$  ou grandes números de eventos  $k$ .

### 21.1.2 Técnica da Inversão Usando a Fórmula Recursiva

Para gerar uma variável aleatória de Poisson usando a técnica da inversão e a fórmula recursiva, o processo é o seguinte:

1. Gerar um número aleatório uniforme  $u \in [0, 1)$ .
2. Calcular a CDF acumulada para valores de  $k$ , somando as probabilidades da PMF (usando a relação recursiva) até que a CDF acumulada seja maior ou igual a  $u$ .
3. O menor valor  $k$  tal que  $F(k) \geq u$  será o número de eventos gerado pela distribuição Poisson.

### 21.1.3 Explicação:

1. **Fórmula Recursiva:** A relação recursiva  $P(X = k + 1) = \frac{\lambda}{k+1} \cdot P(X = k)$  permite calcular as probabilidades de forma eficiente, atualizando a probabilidade de  $P(X = k + 1)$  a partir de  $P(X = k)$ .
2. **Eficiência:** Esta técnica evita o cálculo repetido de fatoriais, tornando-a mais eficiente, especialmente quando se está gerando variáveis para grandes valores de  $\lambda$  ou quando se deseja calcular probabilidades para muitos eventos  $k$ .

Este método é amplamente utilizado por ser mais rápido e computacionalmente eficiente para a geração de variáveis aleatórias de Poisson.

## 22 R

```
# Função para gerar a inversa da CDF para a distribuição Poisson usando a técnica de inversão
inversa_cdf_poisson_recurativa <- function(lam, u) {
  k <- 0
  p <- exp(-lam) # P(X=0)
  F <- p # Iniciamos com a probabilidade P(X=0)

  # Continuamos somando até que F >= u
  while (u > F) {
    k <- k + 1
    p <- p * lam / k # Atualiza a probabilidade recursivamente para o próximo valor
    F <- F + p
  }

  return(k)
}

# Parâmetro lambda da distribuição Poisson
lam <- 3

# Gerando 1000 números uniformemente distribuídos
uniformes <- runif(1000)

# Gerando a variável aleatória Poisson correspondente para cada número uniforme
poisson_vars <- sapply(uniformes, inversa_cdf_poisson_recurativa, lam = lam)


# Plotando o histograma das variáveis Poisson geradas
library(ggplot2)

df <- data.frame(poisson_vars = poisson_vars)
ggplot(df, aes(x = poisson_vars)) +
  geom_histogram(bins = max(poisson_vars) + 1, color = "black", fill = "skyblue", boundary =
  labs(title = "Histograma de Variáveis Aleatórias Poisson Usando a Fórmula Recursiva ( = 3)",
    x = "Valor da Variável Aleatória Poisson",
    y = "Frequência") +
```



```
theme_minimal() +
theme(panel.grid.major = element_blank())
```

## Histograma de Variáveis Aleatórias Poisson Usando a Fórmula




```
# Função para calcular a CDF da distribuição Poisson
cdf_poisson <- function(k, lam) {
  cdf <- 0
  p <- exp(-lam) # P(X=0)
  for (i in 0:k) {
    cdf <- cdf + p # Adiciona a probabilidade à CDF
    if (i < k) {
      p <- p * lam / (i + 1) # Atualiza a probabilidade recursivamente
    }
  }
  return(cdf)
}

# Gerando valores de k para a CDF
k_values <- 0:14
cdf_values <- sapply(k_values, cdf_poisson, lam = lam)

# Plotando a CDF da distribuição Poisson
df_cdf <- data.frame(k_values = k_values, cdf_values = cdf_values)
ggplot(df_cdf, aes(x = k_values, y = cdf_values)) +
```

```
geom_step(direction = "hv", color = "blue", size = 1.5) +
labs(title = "CDF da Distribuição Poisson Usando a Fórmula Recursiva ( λ = 3)",
     x = "k (Número de eventos)",
     y = "F(k)") +
theme_minimal() +
theme(panel.grid.major = element_blank())
```



## 23 Python

```
import numpy as np
import matplotlib.pyplot as plt
import math

# Função para gerar a inversa da CDF para a distribuição Poisson usando a técnica de inversão
def inversa_cdf_poisson_recurativa(lam, u):
    k = 0
    p = math.exp(-lam) # P(X=0)
    F = p # Iniciamos com a probabilidade P(X=0)

    # Continuamos somando até que F >= u
    while u > F:
        k += 1
        p = p * lam / k # Atualiza a probabilidade recursivamente para o próximo valor
        F += p

    return k


# Parâmetro lambda da distribuição Poisson
lam = 3

# Gerando 1000 números uniformemente distribuídos
uniformes = np.random.uniform(0, 1, 1000)

# Gerando a variável aleatória Poisson correspondente para cada número uniforme
poisson_vars = [inversa_cdf_poisson_recurativa(lam, u) for u in uniformes]

# Plotando o histograma das variáveis Poisson geradas
plt.figure(figsize=(10, 6))
plt.hist(poisson_vars, bins=range(0, max(poisson_vars) + 1), color='skyblue', edgecolor='black')
plt.title('Histograma de Variáveis Aleatórias Poisson Usando a Fórmula Recursiva (λ = 3)')
plt.xlabel('Valor da Variável Aleatória Poisson')
plt.ylabel('Frequência')
plt.grid(True)
```

```
plt.show()
```




```
# Calculando a CDF da distribuição Poisson
def cdf_poisson(k, lam):
    cdf = 0
    p = math.exp(-lam) # P(X=0)
    for i in range(k+1):
        cdf += p # Adiciona a probabilidade à CDF
        if i < k: # Atualiza a probabilidade recursivamente
            p = p * lam / (i + 1)
    return cdf

# Gerando valores de k para a CDF
k_values = np.arange(0, 15)
cdf_values = [cdf_poisson(k, lam) for k in k_values]

# Plotando a CDF da distribuição Poisson
plt.figure(figsize=(10, 6))
plt.step(k_values, cdf_values, where='post', color='blue', label='CDF Poisson', linewidth=2)
plt.title('CDF da Distribuição Poisson Usando a Fórmula Recursiva (  $\lambda = 3$  )')
plt.xlabel('k (Número de eventos)')
```

```
plt.ylabel('F(k)')
plt.grid(True)
plt.legend()
plt.show()
```



## 23.1 Exercícios

**Exercício 1.** Seja  $X$  uma v.a. tal que  $\mathbb{P}(X = 1) = 0.3$ ,  $\mathbb{P}(X = 3) = 0.1$  e  $\mathbb{P}(X = 4) = 0.6$ .

- Escreva um pseudo-algoritmo para gerar um valor de  $X$ .
- Implemente uma função para gerar  $n$  valores de  $X$ .
- Compare a distribuição das frequências obtidas na amostra simulada com as probabilidades reais.

**Exercício 2.** Considere  $X$  uma v.a. tal que

$$\mathbb{P}(X = i) = \alpha \mathbb{P}(X_1 = i) + (1 - \alpha) \mathbb{P}(X_2 = i), \quad i = 0, 1, \dots$$

onde  $0 \leq \alpha \leq 1$  e  $X_1, X_2$  são v.a. discretas.

A distribuição de  $X$  é chamada de distribuição de mistura. Podemos escrever

$$X = \begin{cases} X_1, & \text{com probabilidade } \alpha \\ X_2, & \text{com probabilidade } 1 - \alpha \end{cases}$$

Pseudo-Algoritmo:

- (1) Seja  $U \sim Unif(0, 1)$
- (2) Se  $U \leq \alpha$ , gere um valor da distribuição de  $X_1$ . Senão, gere um valor da distribuição de  $X_2$

Com base no pseudo-algoritmo implemente um algoritmo para gerar uma amostra de tamanho  $n$  da distribuição mistura de uma Poisson e de uma Geométrica com base nas funções implementadas nos Exercícios (2) e (3).

## 24 Geração de Variáveis Aleatórias Contínuas Usando a Técnica da Inversão e Transformações

Os valores que uma variável aleatória  $X$  pode assumir são chamados de **suporte** da distribuição de  $X$ .

**Variáveis Aleatórias Contínuas** são variáveis aleatórias que têm suporte em um conjunto não enumerável de valores, como intervalos na reta real,  $\mathbb{R}$ , ou  $(0, \infty)$ , por exemplo.

Uma variável aleatória  $X$  contínua tem função de distribuição acumulada (f.d.a.) puder ser expressa como

$$P(X \leq a) = F(a) = \int_{-\infty}^a f(x)dx, \quad \forall a \in \mathbb{R},$$

em que  $f : \mathbb{R} \rightarrow [0, \infty)$  é uma função integrável, chamada de função densidade de probabilidade.

### 24.1 Função Inversa

Sabemos que  $F : \mathbb{R} \rightarrow [0, 1]$  é estritamente crescente quando  $X$  é contínua, e, portanto, podemos definir sua função inversa  $F^{-1} : [0, 1] \rightarrow \mathbb{R}$ . A seguinte figura ilustra  $F$  e sua inversa.

## 25 R

```
# Carregando as bibliotecas necessárias
library(ggplot2)

# Definindo a função de distribuição acumulada F(x) - função logística
F <- function(x) {
  return(1 / (1 + exp(-x)))
}

# Definindo a inversa da função de distribuição acumulada F_inv(u)
F_inv <- function(u) {
  return(-log((1 / u) - 1))
}


# Gerando valores de x e u
x <- seq(-4, 10, length.out = 400)
u <- seq(0.01, 0.99, length.out = 400)

# Definindo o valor de U para plotar as linhas
u_value <- 0.7
x_value <- F_inv(u_value)

# Criando o gráfico
ggplot(data = data.frame(x = x, F_x = F(x))) +
  geom_line(aes(x = x, y = F_x), color = "black") +
  geom_hline(yintercept = u_value, linetype = "dotted", color = "red") +
  geom_vline(xintercept = x_value, linetype = "dotted", color = "red") +
  annotate("text", x = x_value - 0.4, y = -0, label = expression(F^{-1}(u)), color = "red", size = 5) +
  annotate("text", x = -5.5, y = u_value - 0.02, label = "u", color = "red", size = 5) +
  labs(title = "Representação da Função de Distribuição Acumulada e sua Inversa",
       x = "x", y = "F(x)") +
  ylim(0, 1.2) +
  theme_minimal()
```



Representação da Função de Distribuição Acumulada e sua Inversa



## 26 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Definindo a função de distribuição acumulada F(x)
def F(x):
    return 1 / (1 + np.exp(-x)) # Função logística como exemplo de F(x)

# Definindo a inversa da função de distribuição acumulada F_inv(u)
def F_inv(u):
    return -np.log((1 / u) - 1)

# Gerando valores de x e u para plotar
x = np.linspace(-4, 10, 400)
u = np.linspace(0.01, 0.99, 400) # U entre 0 e 1 (evitando extremos para evitar erros na in

# Plotando a função de distribuição acumulada F(x) com truncamento do eixo y no zero
plt.figure(figsize=(8, 6))
plt.plot(x, F(x), color="black")

# Adicionando linhas pontilhadas para representar U e F_inv(U)
u_value = 0.7 # Exemplo de valor de U
x_value = F_inv(u_value)

plt.hlines(u_value, min(x), x_value, linestyles='dotted', colors='red')
plt.vlines(x_value, 0, u_value, linestyles='dotted', colors='red')

# Etiquetas
plt.text(x_value-0.4, -0.05, r"$F^{-1}(u)$", fontsize=12, color='red')
plt.text(-5.5, u_value - 0.02, r"$u$", fontsize=14, color='red')

# Rótulos e estilo do gráfico
plt.title(r'Representação da Função de Distribuição Acumulada e sua Inversa', fontsize=14)
plt.xlabel(r'$x$', fontsize=12)
plt.ylabel(r'$F(x)$', fontsize=12)
```

```
plt.ylim(0, 1.2)
```


```
(0.0, 1.2)
```

```
plt.xlim(-4, 10)
```

```
(-4.0, 10.0)
```

```
plt.grid(True)
```

```
# Exibir o gráfico  
plt.show()
```



## 26.1 Método da Inversão

Uma maneira de gerar valores de uma variável aleatória contínua  $X$ , é o **método da inversão**, que é originado da seguinte proposição:

**Proposição:** Seja  $U \sim \text{Unif}(0, 1)$ . Para qualquer variável aleatória contínua com função de distribuição acumulada  $F$ , a variável:

$$X = F^{-1}(U)$$

tem distribuição  $F$ .

**Prova:**

$$\mathbb{P}(X \leq x) = \mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(F(F^{-1}(U)) \leq F(x)) = \mathbb{P}(U \leq F(x)) = F(x).$$

Assim, o método da inversão consiste em:

1. Gerar  $U \sim \text{Unif}(0, 1)$ .
2. Calcular  $X = F^{-1}(U)$ .

## 26.2 Exemplo 1

Seja  $X$  uma v.a. com:

$$F(x) = x^n, \quad \text{para } 0 < x < 1.$$

A função inversa é:

$$u = F(x) = x^n \implies x = u^{1/n}.$$

Portanto, o pseudo-algoritmo para gerar  $X$  a partir do método da inversão é:

1. Gere  $U \sim \text{Unif}(0, 1)$ .
2. Calcule  $X = U^{1/n}$ .

## 27 R

```
# Carregar a biblioteca ggplot2
library(ggplot2)

# Definir o parâmetro n da distribuição  $F(x) = x^n$ 
n <- 3

# Gerar 1000 valores U de uma distribuição uniforme (0,1)
U <- runif(1000, min = 0, max = 1)


# Calcular  $X = U^{(1/n)}$ 
X <- U^(1/n)

# Criar um dataframe para o ggplot2
data <- data.frame(X = X)

# Plotar o histograma usando ggplot2
p <- ggplot(data, aes(x = X)) +
  geom_histogram(aes(y = ..density..), bins = 30, fill = 'skyblue', color = 'black') +
  labs(title = 'Histograma de variáveis geradas pela inversão:  $F(x) = x^n$ ,  $n = 3$ ',
       x = 'Valor de X', y = 'Frequência') +
  theme_minimal() +
  theme(plot.title = element_text(size = 14),
        axis.title.x = element_text(size = 12),
        axis.title.y = element_text(size = 12))

# Exibir o gráfico
print(p)
```

Histograma de variáveis geradas pela inversão:  $F(x) = x^n$ ,



## 28 Python


```
import numpy as np
import matplotlib.pyplot as plt

# Parâmetro n da distribuição  $F(x) = x^n$ 
n = 3

# Gerando 1000 valores U de uma distribuição uniforme (0,1)
U = np.random.uniform(0, 1, 1000)

# Calculando  $X = U^{1/n}$ 
X = U**(1/n)

# Plotando um histograma dos valores gerados
plt.figure(figsize=(10, 6))
plt.hist(X, bins=30, color='skyblue', edgecolor='black', density=True)
plt.title('Histograma de variáveis geradas pela inversão:  $F(x) = x^n$ ,  $n = 3$ ')
plt.xlabel('Valor de X')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



### 28.0.1 Exemplo 2

Seja  $X \sim \text{Exp}(\lambda)$ , com:

$$F(x) = 1 - e^{-\lambda x}, \quad \text{para } x > 0.$$

A função inversa é:

$$u = F(x) = 1 - e^{-\lambda x} \implies x = -\frac{\log(1-u)}{\lambda}.$$

Um pseudo-algoritmo para gerar  $X$  é, portanto,:

1. Gere  $U \sim \text{Unif}(0, 1)$ .
2. Calcule  $X = -\frac{\log(1-U)}{\lambda}$ .



## 29 R

```
# Carregar a biblioteca ggplot2
library(ggplot2)

# Definir o parâmetro lambda da distribuição exponencial
lambda <- 2

# Gerar 1000 valores U de uma distribuição uniforme (0,1)
U <- runif(1000, min = 0, max = 1)


# Calcular X usando a inversa da CDF da distribuição exponencial
X <- -log(1 - U) / lambda

# Criar um dataframe para o ggplot2
data <- data.frame(X = X)

# Plotar o histograma usando ggplot2
p <- ggplot(data, aes(x = X)) +
  geom_histogram(aes(y = ..density..), bins = 30, fill = 'lightcoral', color = 'black') +
  labs(title = 'Histograma de variáveis geradas pela inversão: Distribuição Exponencial',
        x = 'Valor de X', y = 'Frequência') +
  theme_minimal() +
  theme(plot.title = element_text(size = 14),
        axis.title.x = element_text(size = 12),
        axis.title.y = element_text(size = 12))

# Exibir o gráfico
print(p)
```

Histograma de variáveis geradas pela inversão: Distribuição



## 30 Python


```
import numpy as np
import matplotlib.pyplot as plt

# Parâmetro lambda da distribuição exponencial
lamdb = 2

# Gerando 1000 valores U de uma distribuição uniforme (0,1)
U = np.random.uniform(0, 1, 1000)

# Calculando X usando a inversa da CDF da exponencial
X = -np.log(1 - U) / lamdb

# Plotando um histograma dos valores gerados
plt.figure(figsize=(10, 6))
plt.hist(X, bins=30, color='lightcoral', edgecolor='black', density=True)
plt.title('Histograma de variáveis geradas pela inversão: Distribuição Exponencial')
plt.xlabel('Valor de X')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



## 30.1 Simulação de transformações de variáveis aleatórias

Agora que já sabemos uma maneira de simular uma variável aleatória  $X$ , descreveremos como gerar valores de uma transformação dessa variável, ou seja,  $g(X)$ . Para isso, basta aplicar a função de transformação  $g$  diretamente aos valores simulados de  $X$ . Veremos a seguir alguns exemplos disso em funcionamento.

---

### 30.1.1 Exemplo 1: Simulando $Y \sim Unif(1, 2)$

Para gerar valores de  $Y \sim Unif(1, 2)$ , usamos o fato de que  $Y$  é uma simples transformação de  $U \sim Unif(0, 1)$ . A relação é:

$$Y = U + 1.$$

Assim, podemos usar o seguinte pseudo-algoritmo para gerar  $Y$  a partir de  $U$ :

1. Gere  $U \sim Unif(0, 1)$ .
2. Calcule  $Y = U + 1$ .

## 31 R

```
# Carregar biblioteca ggplot2
library(ggplot2)

# Gerar 1000 valores U de uma distribuição uniforme (0,1)
U <- runif(1000, min = 0, max = 1)


# Calcular Y = U + 1 para ter Y ~ Unif(1, 2)
Y <- U + 1

# Criar um dataframe para o ggplot2
data <- data.frame(Y = Y)

# Plotar o histograma usando ggplot2
p <- ggplot(data, aes(x = Y)) +
  geom_histogram(aes(y = ..density..), bins = 30, fill = 'skyblue', color = 'black') +
  labs(title = 'Histograma de variáveis geradas: Y ~ Unif(1, 2)',
       x = 'Valor de Y', y = 'Frequência') +
  theme_minimal() +
  theme(plot.title = element_text(size = 14),
        axis.title.x = element_text(size = 12),
        axis.title.y = element_text(size = 12))

# Exibir o gráfico
print(p)
```

Histograma de variáveis geradas:  $Y \sim \text{Unif}(1, 2)$




## 32 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Gerando 1000 valores U de uma distribuição uniforme (0,1)
U = np.random.uniform(0, 1, 1000)

# Calculando Y = U + 1 para ter Y ~ Unif(1, 2)
Y = U + 1

# Plotando um histograma dos valores gerados
plt.figure(figsize=(10, 6))
plt.hist(Y, bins=30, color='skyblue', edgecolor='black', density=True)
plt.title('Histograma de variáveis geradas: Y ~ Unif(1, 2)')
plt.xlabel('Valor de Y')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



### 32.0.1 Exemplo 2: Simulando $Y \sim \text{Gamma}(n, \lambda)$

Para gerar valores de  $Y \sim \Gamma(n, \lambda)$ , usamos o fato de que a soma de que  $Y$  pode ser representado como

$$Y = \sum_{i=1}^n X_i,$$

em que cada  $X_i \sim \text{Exp}(\lambda)$ , e  $X_i$ 's são independentes.

Assim, podemos gerar  $Y$  da seguinte forma:

1. Gere  $U_1, \dots, U_n \sim \text{Unif}(0, 1)$  independentemente.
2. Calcule  $X_i = -\frac{\log(1-U_i)}{\lambda}$  para  $i = 1, \dots, n$ .
3. Calcule  $Y = X_1 + X_2 + \dots + X_n$ .



## 33 R

```
# Carregar biblioteca ggplot2
library(ggplot2)

# Definir parâmetros
n <- 5 # número de somas
lambda <- 2 # parâmetro da distribuição exponencial

# Gerar 1000 valores U para cada uma das n somas
U <- matrix(runif(1000 * n, min = 0, max = 1), ncol = n)

# Calcular  $X_i = -\log(1 - U_i) / \lambda$  para cada  $U_i$ 
X <- -log(1 - U) / lambda


# Somar os valores de X para obter  $Y \sim \text{Gamma}(n, \lambda)$ 
Y <- rowSums(X)

# Criar um dataframe para o ggplot2
data <- data.frame(Y = Y)

# Plotar o histograma usando ggplot2
p <- ggplot(data, aes(x = Y)) +
  geom_histogram(aes(y = ..density..), bins = 30, fill = 'lightcoral', color = 'black') +
  labs(title = paste('Histograma de variáveis geradas: Y ~ Gamma(', n, ', ', ' ', lambda, ')'),
       x = 'Valor de Y', y = 'Frequência') +
  theme_minimal() +
  theme(plot.title = element_text(size = 14),
        axis.title.x = element_text(size = 12),
        axis.title.y = element_text(size = 12))

# Exibir o gráfico
print(p)
```

Histograma de variáveis geradas:  $Y \sim \text{Gamma}(5, 2)$



## 34 Python

```
import numpy as np
import matplotlib.pyplot as plt


# Definindo parâmetros
n = 5 # número de somas
lamdb = 2 # parâmetro da distribuição exponencial

# Gerando 1000 valores U para cada uma das n somas
U = np.random.uniform(0, 1, (1000, n))

# Calculando  $X_i = -\log(1 - U_i) / \lambda$  para cada  $U_i$ 
X = -np.log(1 - U) / lamdb

# Somando os valores de X para obter  $Y \sim \text{Gamma}(n, \lambda)$ 
Y = np.sum(X, axis=1)

# Plotando um histograma dos valores gerados
plt.figure(figsize=(10, 6))
plt.hist(Y, bins=30, color='lightcoral', edgecolor='black', density=True)
plt.title(f'Histograma de variáveis geradas:  $Y \sim \text{Gamma}(\{n\}, \{\lambda\})$ ')
plt.xlabel('Valor de Y')
plt.ylabel('Frequência')
plt.grid(True)
plt.show()
```



## 34.1 Exercícios

### Exercício 1.

Utilizando o método da inversão, simule  $U \sim U(1, 3)$ .

### Exercício 2.

- Implemente uma função para gerar uma amostra de tamanho  $n$  da distribuição Exponencial de parâmetro  $\lambda$ .
- Compare a distribuição empírica dos valores simulados com a densidade da Exponencial  $f(x) = \lambda e^{-\lambda x}, x > 0$ .

### Exercício 3.

- Implemente uma função para gerar uma amostra de tamanho  $n$  da distribuição  $Gama(a, b)$ , para  $a$  sendo um valor inteiro.
- Compare a distribuição empírica dos valores simulados com a densidade da Gama  $f(x) = \frac{b^a}{\Gamma(a)} x^{a-1} e^{-bx}, x > 0$ .

**Exercício 4.** Seja  $X$  uma v.a. com função densidade dada por:

$$f(x) = \frac{1}{8}x, \quad 0 < x < 4.$$

- a) Escreva um pseudo-algoritmo para simular um único valor da variável  $X$  pelo método da inversão.
- b) Compare a distribuição empírica dos valores simulados com a densidade de  $X$ .

## **35 Geração de Variáveis Aleatórias Discretas Usando o Método da Rejeição**

Fill in

## 36 Geração de Variáveis Aleatórias Contínuas Usando o Método da Rejeição

A amostragem por rejeição é uma técnica útil para gerar variáveis aleatórias a partir de uma distribuição complexa, utilizando uma distribuição proposta mais simples. A ideia básica é simular de uma distribuição fácil de amostrar e, em seguida, rejeitar ou aceitar essas amostras com base na distribuição alvo.

### 36.1 Algoritmo

O método assume que conhecemos uma distribuição  $g(x)$ , fácil de simular, que cubra o suporte da distribuição alvo  $f(x)$ . Essa distribuição é chamada de **distribuição proposta**. Além disso ele assume que existe  $c$  tal que  $\frac{f(x)}{g(x)} \leq c$  para todo  $x$ , e que conseguimos calcular  $c$ . O método de aceitação e rejeição segue os seguintes passos:

1. Gere um valor  $Y$  da distribuição proposta  $g(x)$ .
2. Gere um valor  $U \sim \text{Uniform}(0, 1)$ .
3. Aceite  $Y$  como uma amostra de  $f(x)$  se  $U \leq \frac{f(Y)}{c \cdot g(Y)}$ , caso contrário, rejeite  $Y$  e repita o processo.

A figura a seguir ilustra esse processo quando  $g$  é uma distribuição uniforme entre 0 e 1.

## 37 R

```
library(ggplot2)

# Função densidade alvo f(x)
f <- function(x) {
  20 * x * (1 - x)^3
}

# Função densidade proposta g(x) (distribuição uniforme)
g <- function(x) {
  rep(1, length(x)) # g(x) é uniforme no intervalo (0, 1)
}

# Constante c (máximo de f(x))
opt_result <- optimize(f = function(x) -f(x), interval = c(0, 1))
c <- f(opt_result$minimum)

# Gerar valores de x
x <- seq(0, 1, length.out = 1000)

# Valor de Y para aceitar/rejeitar (escolhido aleatoriamente)
Y <- 0.6

# DataFrame para o gráfico
df <- data.frame(x = x, fx = f(x), gx = c * g(x))

# Plotando as funções f(x) e a linha horizontal c*g(x)
ggplot(df, aes(x = x)) +
  geom_line(aes(y = fx, color = "f(x)"), size = 1) +
  geom_hline(aes(yintercept = c * g(x), color = "c * g(x)"), size = 1.5) +

  # Destacar a área de aceitação e rejeição
  geom_text(aes(x = Y + 0.025, y = 0.05, label = "Y"), color = "black", size = 5) +

  geom_segment(aes(x = Y, xend = Y, y = 0, yend = f(Y)), color = "green", size = 1.5) +
```



```

geom_segment(aes(x = Y, xend = Y, y = f(Y), yend = c * g(Y)), color = "red", size = 1.5) +

# Mover rótulos de Aceitar/Rejeitar para a esquerda da linha Y
geom_text(aes(x = Y + 0.06, y = f(Y) / 2, label = "Aceitar x"), color = "green", size = 4)
geom_text(aes(x = Y + 0.06, y = f(Y) + (c * g(Y) - f(Y)) / 2, label = "Rejeitar x"), color = "red", size = 4)


# Limites e rótulos
xlim(0, 1) +
ylim(0, 2.5) +
labs(x = "x", y = "Densidade", title = "Amostragem por Rejeição para g uniforme") +

# Legenda
scale_color_manual(values = c("f(x)" = "black", "c * g(x)" = "blue"), name = "Funções") +

theme_minimal() +
theme(legend.position = "top")

```

### Amostragem por Rejeição para g uniforme



## 38 Python

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.optimize import minimize_scalar

# Função densidade alvo f(x)
def f(x):
    return 20 * x * (1 - x)**3

# Função densidade proposta g(x) (distribuição uniforme)
def g(x):
    return 1 # g(x) é uniforme no intervalo (0, 1)

# Constante c
result = minimize_scalar(lambda x: -f(x), bounds=(0, 1), method='bounded')
c = f(result.x)

# Gerar valores de x
x = np.linspace(0, 1, 1000)

# Valor de Y para aceitar/rejeitar (escolhido aleatoriamente)
Y = 0.6
U = 0.8
accept_threshold = f(Y) / (c * g(Y))

# Plotando as funções f(x) e a linha horizontal c*g(x)
# Ajustando o código para truncar o eixo y no zero
plt.plot(x, f(x), label='f(x)', color='black')
plt.hlines(c * g(x), 0, 1, color='blue', label='c*g(x)', linewidth=2) # Linha horizontal c*g(x)

# Destacar a área de aceitação e rejeição
plt.vlines(Y, 0, f(Y), colors='green', label='Aceitar $x$', linewidth=2)
plt.vlines(Y, f(Y), c * g(Y), colors='red', label='Rejeitar $x$', linewidth=2)

# Adicionar rótulo de Y na posição da linha vertical
```

```
plt.text(Y+0.025, 0.05, 'Y', color='black', fontsize=12, horizontalalignment='center')

# Adicionar rótulos de Aceitar/Rejeitar
plt.text(Y + 0.01, f(Y) / 2, 'Aceitar x', color='green', fontsize=10, verticalalignment='center')
plt.text(Y + 0.01, f(Y) + (c * g(Y) - f(Y)) / 2, 'Rejeitar x', color='red', fontsize=10, verticalalignment='center')

# Limites e rótulos
plt.xlim(0, 1)
```

(0.0, 1.0)


```
plt.ylim(0, 2.5) # Truncando o eixo y no zero
```

(0.0, 2.5)

```
plt.xlabel('x')
plt.ylabel('Densidade')

# Adicionar a legenda para f(x) e c*g(x)
plt.legend(['f(x)', 'c*g(x)'])

# Mostrar gráfico
plt.title('Amostragem por Rejeição para g uniforme')
plt.show()
```



### 38.1 Exemplo

Vamos demonstrar a amostragem por rejeição gerando amostras de uma distribuição alvo  $f(x)$ , utilizando a distribuição uniforme como distribuição proposta.

A função densidade alvo que utilizaremos é:

$$f(x) = 20x(1-x)^3 \quad \text{para } 0 < x < 1$$

E a distribuição proposta será  $g(x) = 1$  para  $0 < x < 1$ , que é uma distribuição uniforme.

Implementamos o seguinte algoritmo:

## 39 R

```
library(ggplot2)

# Função densidade alvo f(x)
f <- function(x) {
  20 * x * (1 - x)^3
}

# Amostragem por rejeição
amostragem_rejeicao <- function(f, c, n_amstras) {
  amostras <- numeric(0)
  while (length(amostras) < n_amstras) {
    # Gere Y ~ g(x) (uniforme entre 0 e 1)
    Y <- runif(1, 0, 1)

    # Gere U ~ Uniforme(0, 1)
    U <- runif(1, 0, 1)

    # Verifica se aceitamos Y
    if (U <= f(Y) / (c)) {
      amostras <- c(amostras, Y)
    }
  }
  return(amostras)
}


# A constante c é o limite superior de f(x)
c <- 135 / 64

# Gere 1000 amostras usando o método de aceitação e rejeição
set.seed(123)
amostras <- amostragem_rejeicao(f, c, 1000)

# Criação do data frame para o ggplot2
x_vals <- seq(0, 1, length.out = 1000)
```

```
f_vals <- f(x_vals)
df <- data.frame(x = x_vals, y = f_vals)

# Gráfico com ggplot2
ggplot() +
  geom_line(data = df, aes(x = x, y = y), color = 'blue', size = 1, linetype = 'solid') +
  geom_histogram(aes(x = amostras, y = ..density..), bins = 30, fill = 'orange', alpha = 0.5)
ggtitle("Amostragem por Rejeição") +
  xlab("x") +
  ylab("Densidade") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5))
```



## 40 Python

```
import numpy as np
import matplotlib.pyplot as plt

# Função densidade alvo f(x)
def f(x):
    return 20 * x * (1 - x)**3

# Função densidade proposta g(x) (distribuição uniforme)
def g(x):
    return 1 # g(x) é uniforme no intervalo (0, 1)

# Amostragem por rejeição
def amostragem_rejeicao(f, g, c, n_amstras):
    amostras = []
    while len(amostras) < n_amstras:
        # Gere Y ~ g(x)
        Y = np.random.uniform(0, 1)

        # Gere U ~ Uniforme(0, 1)
        U = np.random.uniform(0, 1)

        # Verifica se aceitamos Y
        if U <= f(Y) / (c * g(Y)):
            amostras.append(Y)


    return np.array(amostras)

# A constante c é o limite superior de f(x)/g(x)
c = 135 / 64 # Pré-calculado

# Gere 1000 amostras usando o método de aceitação e rejeição
amostras = amostragem_rejeicao(f, g, c, 1000)

# Plotando os resultados
```

```
x = np.linspace(0, 1, 1000)
plt.plot(x, f(x), label='Distribuição Alvo f(x)')
plt.hist(amostras, bins=30, density=True, alpha=0.5, label='Amostragem por Rejeição')
plt.legend()
plt.title("Amostragem por Rejeição")
plt.show()
```



## 40.1 Resultados Teóricos

### 40.1.1 Correção do Método de Aceitação e Rejeição

#### Teorema:

A variável aleatória  $Y$  gerada pelo método da rejeição tem densidade  $f(x)$ .

#### Prova:

Considere a função de distribuição acumulada (CDF) de  $X$ , a variável gerada pelo método:

$$P(X \leq x) = P(Y \leq x \mid \text{aceitar } Y)$$

Podemos escrever essa probabilidade como:



$$P(X \leq x) = \frac{P(Y \leq x, U \leq \frac{f(Y)}{c \cdot g(Y)})}{P(U \leq \frac{f(Y)}{c \cdot g(Y)})}$$

Usando a probabilidade condicional, o numerador pode ser expresso como:

$$P(Y \leq x, U \leq \frac{f(Y)}{c \cdot g(Y)}) = \int_{-\infty}^x \int_0^{\frac{f(y)}{c \cdot g(y)}} g(y) du dy$$

Resolvendo a integral em  $u$ :

$$P(Y \leq x, U \leq \frac{f(Y)}{c \cdot g(Y)}) = \int_{-\infty}^x \frac{f(y)}{c \cdot g(y)} g(y) dy = \frac{1}{c} \int_{-\infty}^x f(y) dy$$

De maneira semelhante, o denominador é dado por:

$$P\left(U \leq \frac{f(Y)}{c \cdot g(Y)}\right) = \int_{-\infty}^{\infty} \frac{f(y)}{c \cdot g(y)} g(y) dy = \frac{1}{c} \int_{-\infty}^{\infty} f(y) dy$$

Como  $\int_{-\infty}^{\infty} f(y) dy = 1$  (pois  $f(x)$  é uma função densidade), o denominador resulta em  $\frac{1}{c}$ . Substituindo essas expressões na equação original, obtemos:

$$P(X \leq x) = \frac{\frac{1}{c} \int_{-\infty}^x f(y) dy}{\frac{1}{c}} = \int_{-\infty}^x f(y) dy$$

Portanto, a variável  $X$  gerada pelo método de aceitação e rejeição tem função de distribuição acumulada  $\int_{-\infty}^x f(y) dy$ , o que implica que  $X$  tem densidade  $f(x)$ . Assim, o método gera amostras corretamente distribuídas de acordo com  $f(x)$ , como desejado.

### 40.1.2 Eficiência computacional

#### Teorema:

A variável aleatória gerada pelo método de aceitação e rejeição tem função de densidade  $f(x)$ . O número de passos que o algoritmo necessita para gerar  $X$  tem distribuição geométrica com média  $c$ , onde  $c$  é a constante de normalização que define o limite superior da razão  $\frac{f(x)}{g(x)}$ .

#### Prova:

Seja  $Y$  a variável aleatória gerada pela distribuição proposta  $g(x)$ , e  $U \sim \text{Unif}(0, 1)$  uma variável aleatória uniforme. O método de aceitação e rejeição aceita  $Y$  como amostra de  $f(x)$  se  $U \leq \frac{f(Y)}{cg(Y)}$ , caso contrário, o valor é rejeitado e o processo é repetido.

A probabilidade de aceitar uma amostra  $Y$ , dado que  $Y \leq x$ , é dada por:

$$P(Y \leq x \text{ e aceitar}) = P\left(Y \leq x, U \leq \frac{f(Y)}{cg(Y)}\right)$$

Podemos reescrever essa probabilidade como uma integral:

$$P(Y \leq x \text{ e aceitar}) = \int_{-\infty}^x \int_0^{\frac{f(y)}{cg(y)}} g(y) du dy$$

Resolvendo a integral em  $u$ , temos:

$$P(Y \leq x \text{ e aceitar}) = \int_{-\infty}^x \frac{f(y)}{cg(y)} g(y) dy = \frac{1}{c} \int_{-\infty}^x f(y) dy$$

A probabilidade de aceitar qualquer valor  $Y$  é dada por:

$$P(\text{aceitar}) = P\left(U \leq \frac{f(Y)}{cg(Y)}\right) = \int_{-\infty}^{\infty} \int_0^{\frac{f(y)}{cg(y)}} g(y) du dy$$

Simplificando:

$$P(\text{aceitar}) = \int_{-\infty}^{\infty} \frac{f(y)}{cg(y)} g(y) dy = \frac{1}{c} \int_{-\infty}^{\infty} f(y) dy = \frac{1}{c}$$

Assim, a cada passo, a probabilidade de aceitar um valor é  $\frac{1}{c}$ , o que implica que o número de passos necessários para aceitar uma amostra tem distribuição geométrica com média  $c$ .

Por fim, sabemos que a função de distribuição acumulada da variável  $X$ , dado que ela foi aceita, é:

$$P(X \leq x) = P(Y \leq x \mid \text{aceitou}) = \frac{P(Y \leq x, \text{aceitou})}{P(\text{aceitar})}$$

Substituindo as expressões:

$$P(X \leq x) = \frac{\frac{1}{c} \int_{-\infty}^x f(y) dy}{\frac{1}{c}} = \int_{-\infty}^x f(y) dy$$

Portanto, a variável  $X$  gerada pelo método de aceitação e rejeição tem função de densidade  $f(x)$ , como desejado.

## 40.2 Exercícios

**Exercício 1.** Seja  $X \sim \text{Gama}(3/2, 1)$  com função densidade dada por

$$f(x) = \frac{1}{\Gamma(3/2)} x^{1/2} e^{-x}, \text{ para } x > 0.$$

- a) Escreva um pseudo-algoritmo para simular um valor da distribuição de  $X$  usando o método da aceitação e rejeição usando como distribuição proposta a distribuição exponencial de parâmetro  $2/3$ .

*Observação:* Note que  $\mathbb{E}[X] = 3/2$  e  $\mathbb{E}[Y] = 3/2$ , por isso o parâmetro da distribuição exponencial proposta foi tomado como  $2/3$ .

- b) Crie uma função para gerar um valor de  $X$ .
- c) Qual foi o número de passos necessários para gerar um valor de  $X$ ? Compare com o valor real.
- d) Crie uma função para gerar uma amostra de tamanho  $n$  de  $X$ .
- e) Qual foi o número médio de passos necessários para gerar a amostra de tamanho  $n$ ?
- f) Compare a distribuição empírica dos valores simulados com a distribuição real de  $X$ .

## References

Ross, Sheldon M. 2006. *Simulation, Fourth Edition*. USA: Academic Press, Inc.